

Cursor Skills 封装成一键对抗阅读

从零搭建：Project Rules + Skill + 双AI文件交接 + Judge输出

版本：v2.0 修复版

用途：详细教学流程 / 可直接照做

对象：Cursor + GLM 5.1 双AI对抗文献阅读项目

重要说明：本版采用支持中文的字体重新排版，避免上一版PDF出现方块乱码。本文档讲的是具体落地操作，不是概念介绍。

目录

1. 你要做成什么效果
2. 先理解：Skill、Rules、Commands、两个模型分别负责什么
3. 第0步：准备工作与文件夹
4. 第1步：建立项目目录
5. 第2步：写Project Rules
6. 第3步：创建Cursor Skill
7. 第4步：给Skill配套参考文件
8. 第5步：加入一键初始化脚本
9. 第6步：第一次实际运行
10. 第7步：让两个AI真正对抗
11. 第8步：检查输出是否合格
12. 常见问题与修复
13. 可复制的完整提示词
14. 最终验收清单
15. 参考依据

1. 你要做成什么效果

你要把现在 Cursor 里的两个对话框变成一个可复用的“对抗阅读流水线”。最终不是让两个AI随便聊天，而是让它们围绕同一篇论文、同一个问题产生四类文件：AI-A初稿、AI-B批判、AI-A修正版、Judge评分与JSONL训练数据。

最终效果：你只需要在Cursor Agent里输入一句：“使用 adversarial-lit-reading skill，对 papers/uav001.pdf 执行一键对抗阅读，问题是：该方法是否需要预设声源数？” Cursor就会按固定目录生成提示词、输出文件、检查清单和训练数据草稿。

模块	你看到的形式	实际作用
Cursor Project Rules	<code>.cursor/rules/*.mdc</code>	项目长期规则，约束所有Agent都要遵守：证据优先、不能覆盖文件、不能幻觉。
Cursor Skill	<code>.cursor/skills/adversarial-lit-reading/SKILL.md</code>	封装一套流程，让Agent知道什么时候启动对抗阅读、按什么步骤做。
AI-A	Cursor自己的模型	负责主阅读、结构化总结、修正答案。
AI-B	GLM 5.1对话框	负责对AI-A进行批判、反驳、找漏洞。
Judge	Cursor或GLM任意一个模型，建议Cursor先做	负责评分、判断是否入库、生成JSONL。

边界：如果你没有GLM API，Cursor不能自动“调用”另一个对话框。所谓“一键”，在无API版本里是“一键生成所有文件和给GLM的提示词”，你再把提示词复制到GLM对话框运行。若你后续接入GLM API，则可以升级为真正全自动。

2. 先理解：Skill、Rules、Commands、两个模型分别负责什么

Rules负责“长期约束”，Skill负责“流程封装”。不要把论文内容写进Rules，也不要大量固定流程散落在聊天窗口里。正确做法是：Rules写原则，Skill写步骤，reference文件写角色提示词，rounds文件保存每轮结果。

对象	应该放什么	不应该放什么
Rules	证据要求、文件命名、禁止覆盖、评分阈值	整篇论文、大段临时Prompt、一次性问题
Skill	何时触发、执行顺序、输入输出合同、失败恢复	具体某一篇论文的答案
reference	AI-A/AI-B/Judge提示词模板、评分表、输出模板	每次运行生成的结果
rounds	每一次对抗阅读的实际结果	通用规则
labels	SFT/DPO/RAG评测数据	未经复核的聊天记录

3. 第0步：准备工作与文件夹

你需要准备：

- Cursor已经能打开你的项目。
- Cursor里可以选择你要用的模型，例如Cursor模型。
- 另一个对话框或模型入口可以使用GLM 5.1。
- 论文PDF放在项目内，最好同时准备md/txt文本版。
- 项目根目录不要有中文空格过多的路径，减少脚本路径错误。

建议你先用一篇论文测试，不要一开始批量跑50篇。第一篇论文的目标是跑通流程，第二到第五篇才用于稳定Prompt。

4. 第1步：建立项目目录

在Cursor终端中进入项目根目录，然后执行：

```
mkdir -p adversarial_lit_reading/{papers,chunks,prompts,rounds/A,rounds/B,rounds/
revised,rounds/judge,labels/dpo/raw,labels/dpo/reviewed,labels/sft,labels/
eval,review_needed,rubrics,tools,logs}
mkdir -p .cursor/rules
mkdir -p .cursor/skills/adversarial-lit-reading/reference
mkdir -p .cursor/skills/adversarial-lit-reading/scripts
```

如果你在Windows PowerShell，不支持 `mkdir -p`，可以让Cursor执行下面的Python初始化脚本，或逐个新建文件夹。

5. 第2步：写Project Rules

新建文件：

```
.cursor/rules/adversarial_lit_reading.mdc
```

复制以下内容：

```
# Adversarial Literature Reading Rules

本项目用于双AI对抗式文献阅读训练。

1. 证据优先：所有关键判断必须能回到论文原文。
2. 不确定就标注：原文未明确说明。
3. 禁止幻觉：不得编造章节、表格、公式、结果。
4. 禁止过度外推：实验只证明什么，就只能说到什么程度。
5. 角色隔离：AI-A、AI-B、Judge不能覆盖彼此文件。
6. 文件固定：所有输出必须写入 adversarial_lit_reading/。
7. 可训练化：每轮结果都要能映射为 chosen/rejected/critique。
8. 人工复核：Judge低于8分的样本不进入训练集。
```

检查点：保存后重启Cursor，或重新打开项目。然后在Agent窗口问：“请读取本项目的对抗阅读规则并总结你必须遵守的文件约束。” 如果它能说出不能覆盖AI-A/AI-B/Judge文件，说明Rules生效。

6. 第3步：创建Cursor Skill

新建文件：

```
.cursor/skills/adversarial-lit-reading/SKILL.md
```

复制以下完整内容：

```
---
name: adversarial-lit-reading
description: Use this skill when the user wants one-click adversarial literature reading with
AI-A reader, AI-B critic, AI-A revision, Judge scoring, and JSONL data output.
---

# Adversarial Literature Reading Skill

## 目标
把一篇论文转化为可复核的对抗阅读记录：
1. AI-A 初读：结构化总结和推理。
2. AI-B 批判：检查证据不足、逻辑跳跃、外推过度、方法误解。
3. AI-A 修正：只保留有原文依据的结论。
4. Judge 评分：决定是否进入SFT/DP0数据集。

## 工作原则
- 所有结论必须基于论文原文。
- 不知道就写“原文未明确说明”。
- 不允许把实验结果外推到未测试场景。
- 不允许覆盖其他角色输出文件。
- 输出必须保存到 adversarial_lit_reading/rounds/ 或 labels/。

## 标准文件流
- 输入论文: adversarial_lit_reading/papers/<paper_id>.pdf
- 论文文本: adversarial_lit_reading/chunks/<paper_id>.md
- AI-A 初稿: adversarial_lit_reading/rounds/A/A_round1_<paper_id>_<qid>.md
- AI-B 批判: adversarial_lit_reading/rounds/B/B_attack1_<paper_id>_<qid>.md
- AI-A 修正: adversarial_lit_reading/rounds/revised/A_round2_revised_<paper_id>_<qid>.md
- Judge 评分: adversarial_lit_reading/rounds/judge/J_judge_<paper_id>_<qid>.md
- DP0数据: adversarial_lit_reading/labels/dpo/raw/<paper_id>_<qid>.jsonl

## 执行步骤
当用户说“使用一键对抗阅读”时：
1. 确认 paper_id、论文路径、问题 qid/question。
2. 如果目录不存在，先创建目录。
3. 如果论文没有文本版，提醒用户先把PDF转为md/txt，或让Agent提取关键段落。
4. 根据 reference/role_prompts.md 生成 AI-A、AI-B、Revision、Judge 四个提示词。
5. 先执行 AI-A 初读，并保存到 A 文件。
6. 生成给 GLM 5.1 的 AI-B 批判提示词，保存到 prompts/for_glm_<paper_id>_<qid>.md。
7. 提醒用户把该提示词复制到 GLM 5.1 对话框运行。
8. 用户把 GLM 结果保存为 B 文件后，继续执行 AI-A 修正。
9. 最后执行 Judge 评分，并生成 JSONL。

## 不做的事
- 不直接声称已经训练了模型参数。
- 不在没有API授权的情况下假装自动调用GLM。
- 不把整篇超长论文塞进prompt导致上下文溢出。
```

怎么触发Skill：保存后重启Cursor。在Agent输入“使用 adversarial-lit-reading skill...”或通过技能选择入口手动选择。如果Cursor版本自动检测Skill，它会根据description判断是否加载该Skill。

7. 第4步：给Skill配套参考文件

Skill本体不要太长，否则Agent每次加载都会混乱。把提示词、评分表、模板拆到reference文件夹。

7.1 角色提示词文件

新建：

```
.cursor/skills/adversarial-lit-reading/reference/role_prompts.md
```

```
# role_prompts.md

## AI-A 初读提示词
你是 AI-A：文献主阅读者。请阅读指定论文片段，只基于原文回答问题。
输出结构：
1. 研究问题
2. 方法路径
3. 数据与实验
4. 核心结论
5. 局限与适用边界
6. 对我研究的可迁移价值
要求：每条关键判断必须标注证据位置。如果原文没说，写“原文未明确说明”。

## AI-B 批判提示词
你是 AI-B：对抗审稿人。你的任务不是重新总结，而是审查AI-A答案。
逐条检查：证据不足、证据错配、逻辑跳跃、因果混淆、方法误解、遗漏局限、表述过强。
每条输出：问题编号、AI-A原说法、你的质疑、原文依据、修改建议、严重程度。

## AI-A 修正提示词
你是 AI-A。请根据AI-B批评和原文修正初稿。
要求：删除无证据内容，降级过强表述，补充原文依据，最后写“修正说明”。

## Judge 评分提示词
你是Judge：监督学习数据标注员。
评分：证据准确性0-3，方法理解0-3，逻辑严谨0-2，局限识别0-1，表达清晰0-1。
输出：是否进入DPO，原因，最终标准答案，JSONL字段草稿。
```

7.2 文件合同

新建：

```
.cursor/skills/adversarial-lit-reading/reference/file_contract.md
```

```
# File Contract

每次运行必须提供：
- paper_id: 论文编号，例如 uav001
- qid: 问题编号，例如 q02
- question: 具体问题
- context_file: chunks/<paper_id>.md 或用户指定片段

严禁覆盖：
- AI-A 不得修改 rounds/B/
- AI-B 不得修改 rounds/A/ 和 rounds/revised/
- Judge 不得修改AI-A/AI-B原始输出，只能写 rounds/judge/ 和 labels/

命名格式：
A_round1_<paper_id>_<qid>.md
B_attack1_<paper_id>_<qid>.md
```

```
A_round2_revised_<paper_id>_<qid>.md
J_judge_<paper_id>_<qid>.md
<paper_id>_<qid>.jsonl
```

7.3 评分表

新建：

```
.cursor/skills/adversarial-lit-reading/reference/quality_rubric.md
```

```
# Quality Rubric

总分10分：
- 证据准确性 0-3：证据是否真实存在，是否支持对应结论。
- 方法理解 0-3：是否正确解释输入、模块、算法流程、输出和假设。
- 逻辑严谨 0-2：是否避免因果混淆、外推过度、泛化过强。
- 局限识别 0-1：是否说明适用边界和原文未说明之处。
- 表达清晰 0-1：是否结构清楚、术语稳定、表述谨慎。

进入DPO的最低要求：
- total >= 8
- evidence_accuracy >= 2
- method_understanding >= 2
- chosen明显优于rejected，不是单纯更长
- critique明确指出rejected的问题
```

8. 第5步：加入一键初始化脚本

新建：

```
adversarial_lit_reading/tools/init_adversarial_project.py
```

```
# adversarial_lit_reading/tools/init_adversarial_project.py
from pathlib import Path

ROOT = Path("adversarial_lit_reading")
DIRS = [
    "papers", "chunks", "prompts",
    "rounds/A", "rounds/B", "rounds/revised", "rounds/judge",
    "labels/dpo/raw", "labels/dpo/reviewed", "labels/sft", "labels/eval",
    "review_needed", "rubrics", "tools", "logs"
]

for d in DIRS:
    (ROOT / d).mkdir(parents=True, exist_ok=True)

(ROOT / "README.md").write_text("""# Adversarial Literature Reading

请把论文放入 papers/，把提取后的文本放入 chunks/。
标准流程：AI-A初读 -> AI-B批判 -> AI-A修正 -> Judge评分 -> JSONL。
""", encoding="utf-8")

(ROOT / "rubrics" / "judge_rubric.md").write_text("""# Judge Rubric

证据准确性 0-3
方法理解 0-3
逻辑严谨 0-2
局限识别 0-1
表达清晰 0-1
总分 >= 8 且 evidence_accuracy >= 2 才允许进入DPO。""")
```

```
""" , encoding="utf-8")  
print("OK: adversarial_lit_reading project folders created.")
```

在Cursor终端运行：

```
python adversarial_lit_reading/tools/init_adversarial_project.py
```

成功后，你会看到：

```
OK: adversarial_lit_reading project folders created.
```

9. 第6步：第一次实际运行

9.1 放入论文

把论文放入 `adversarial_lit_reading/papers/`，例如：

```
adversarial_lit_reading/papers/uav001.pdf
```

9.2 准备文本版

如果Cursor能直接读PDF，可以先用PDF；但更稳定的是把关键章节整理成md：

```
adversarial_lit_reading/chunks/uav001.md
```

文本版建议包含：Abstract、Introduction贡献段、Method、Experiment、Ablation、Conclusion/Limitations。

9.3 在Cursor Agent输入：

```
使用 adversarial-lit-reading skill。  
论文: adversarial_lit_reading/papers/uav001.pdf  
文本: adversarial_lit_reading/chunks/uav001.md  
paper_id: uav001  
qid: q02  
question: 该方法是否需要预设声源数？如果需要或不需要，原文依据是什么？  
  
请先生成AI-A初读，并同时生成给GLM 5.1的AI-B批判提示词。
```

这一步结束后应出现两个文件：

```
adversarial_lit_reading/rounds/A/A_round1_uav001_q02.md  
adversarial_lit_reading/prompts/for_glm_attack_uav001_q02.md
```

10. 第7步：让两个AI真正对抗

10.1 把GLM提示词复制到GLM 5.1

打开文件：

```
adversarial_lit_reading/prompts/for_glm_attack_uav001_q02.md
```

全部复制到GLM 5.1对话框。让GLM只做批判，不要让它重写全文。

10.2 保存GLM输出

把GLM输出保存为：

```
adversarial_lit_reading/rounds/B/B_attack1_uav001_q02.md
```

10.3 回到Cursor让AI-A修正

使用 `adversarial-lit-reading skill` 继续 q02。

请读取：

- `rounds/A/A_round1_uav001_q02.md`
- `rounds/B/B_attack1_uav001_q02.md`
- `chunks/uav001.md`

请生成修正版，并保存到：

```
rounds/revised/A_round2_revised_uav001_q02.md
```

10.4 让Judge评分并生成JSONL

继续使用 `adversarial-lit-reading skill`。

请读取AI-A初稿、AI-B批判、AI-A修正版和原文片段。

请按rubric评分，并生成DPO JSONL草稿。

输出到：

```
rounds/judge/J_judge_uav001_q02.md  
labels/dpo/raw/uav001_q02.jsonl
```

11. 第8步：检查输出是否合格

你不要只看文件有没有生成，要看是否满足以下质量要求：

- ☐ AI-A初稿里每个结论都有证据位置。
- ☐ AI-B批判不是泛泛而谈，而是逐条指出“原说法-问题-依据-修改建议”。
- ☐ AI-A修正版明显降低了夸张表述。
- ☐ Judge评分低于8分的样本没有进入DPO正式数据。
- ☐ JSONL能被Python按行读取，没有中文乱码。
- ☐ 同一个paper_id不会同时进入train和test。

12. 常见问题与修复

问题	原因	修复办法
Skill没有出现	目录位置或文件名错误；Cursor尚未重启	确认路径为 .cursor/skills/adversarial-lit-reading/SKILL.md，frontmatter包含name和description，然后重启Cursor。
Agent把所有内容写在聊天里，没有写文件	提示词没有强制输出路径	在请求里写“只写入指定文件，不要只在聊天中回答”。
GLM批判太温和	角色不够明确	提示词写“你的任务是找漏洞，不是鼓励作者；必须指出证据不足和逻辑问题”。
AI-A修正后仍然幻觉	没有强制引用原文	要求每个关键结论必须写证据位置；无证据删掉。
PDF读不全	PDF扫描件或排版复杂	先用工具转成md/txt，或人工摘出Abstract/Method/Experiment。
上下文太长	整篇论文塞入模型	按问题选择相关章节；一个问题一份context。
两个AI覆盖同一文件	文件合同不清楚	固定AI-A写rounds/A和rounds/revised，AI-B只写rounds/B。

13. 可复制的完整提示词

13.1 一键启动提示词

使用 adversarial-lit-reading skill。

请对抗下面论文执行一轮对抗阅读：

- paper_id: <paper_id>
- qid: <qid>
- paper_file: adversarial_lit_reading/papers/<paper_id>.pdf
- context_file: adversarial_lit_reading/chunks/<paper_id>.md
- question: <你的问题>

请按顺序完成：

1. 生成AI-A初稿并保存到 rounds/A/。
2. 生成给GLM 5.1使用的AI-B批判提示词并保存到 prompts/。
3. 不要替GLM伪造批判结果。
4. 等我保存GLM输出后，再继续修正和Judge。

13.2 给GLM的批判提示词模板

你是AI-B：对抗审稿人。

请审查AI-A对论文的回答。你的任务是找漏洞，而不是重新总结全文。

请检查：

1. 哪些结论没有原文证据？
2. 哪些证据与结论不匹配？
3. 哪些地方把相关关系说成因果关系？
4. 哪些地方把实验结果外推到未测试场景？
5. 哪些方法模块理解可能错误？
6. 哪些局限没有写？

输出格式：

- 问题编号
- AI-A原说法
- 你的质疑

- 原文依据
- 修改建议
- 严重程度：高/中/低

13.3 Judge提示词模板

你是Judge：文献阅读训练数据标注员。

请读取AI-A初稿、AI-B批判、AI-A修正版和论文context。

按以下维度评分：

- 证据准确性 0-3
- 方法理解 0-3
- 逻辑严谨 0-2
- 局限识别 0-1
- 表达清晰 0-1

请输出：

1. 总分
2. 是否use_for_dpo
3. 为什么chosen优于rejected
4. 仍需人工复核的问题
5. JSONL草稿

14. 最终验收清单

- ☐ .cursor/rules/adversarial_lit_reading.mdc 已创建。
- ☐ .cursor/skills/adversarial-lit-reading/SKILL.md 已创建。
- ☐ reference/role_prompts.md、file_contract.md、quality_rubric.md 已创建。
- ☐ adversarial_lit_reading 目录完整。
- ☐ 第一篇论文至少跑通 q01-q06 六个问题。
- ☐ 每个问题都有 A_round1、B_attack1、A_round2_revised、J_judge、jsonl。
- ☐ 低分样本进入 review_needed，不进入训练集。
- ☐ 你能用同一句启动Prompt复现第二篇论文。

15. 参考依据

Cursor官方文档说明 Agent Skills 用于用可复用知识与脚本扩展AI Agent；Cursor Rules用于配置持久化指令；Cursor Agent 用于自主执行代码和终端任务。Hugging Face TRL的DPOTrainer文档说明偏好样本通常包含prompt、chosen、rejected等字段。本文档基于这些机制设计项目内可复现流程。