
临床生化+尿液代谢组+系统化 ML 框架非酒精性脂肪肝病无创识别与高风险分层研究

【研究背景】

非酒精性脂肪肝病（NAFLD）全球患病率约 30%，中国疾病负担较重。肝穿刺虽为金标准，但具有创伤性；超声、FibroScan、CAP 或 MRI-PDFF 等影像学工具依赖设备和场景；FLI、HSI、LAP、ZJU 等血清学评分在部分人群，尤其是正常体重或代谢异常不典型人群中灵敏度仍有限。

现有代谢组机器学习研究常见问题包括：算法数量有限、特征选择在交叉验证外完成导致 AUC 被高估、缺少外部代谢组方向验证、模型解释性不足，以及发表后缺乏可使用的部署工具。临床生化和代谢组学也常被分开分析，缺乏统一的系统化 ML 框架。

本研究拟整合患者临床生化、尿液代谢组和中医证型资料，构建“临床代谢异常—尿液代谢重编程—非酒精性脂肪肝病高风险表型”的信息链条，并采用嵌套交叉验证、八算法基准测试、SHAP 解释、公共数据库桥接及 Shiny 部署，形成可解释的无创识别和高风险分层工具。

【研究说明】

1. 文章定位为临床转化型无创诊断与高风险分层研究，同时保留证型代谢分层作为特色分析。
2. 研究核心不是简单回答“有没有非酒精性脂肪肝病”，而是进一步回答哪些非酒精性脂肪肝病患者属于更高风险表型，能否通过常规临床生化指标联合尿液代谢组进行无创识别和分层。
3. 分析顺序遵循：终点设计 → 数据概况 → 特征工程 → 嵌套交叉验证 → 八算法基准测试 → SHAP 可解释性 → 公共数据库桥接 → 临床部署 → 图表输出。
4. 公共数据库部分用于方向一致性、通路层支持和临床变量泛化支持。

【数据情况】

数据来源	数据类型	样本或变量	研究用途
本中心队列	临床生化、尿液代谢组、中医证型资料	正常人 98 例、非酒精性脂肪肝病患者 468 例，共 566 例；患者证型包括无证可辨、肝胆湿热、肝郁脾虚证	作为主建模数据，用于非酒精性脂肪肝病无创识别、高风险分层和证型代谢分层探索
临床生化数据	约 30-40 个临床变量	年龄、体重、身高、性别、心率、血压、ALT、AST、GGT、胆红素、胆汁酸、白蛋白、血糖、尿素氮、肌酐、尿酸、血脂、载脂蛋白等	构建临床变量模型，与传统评分 FLI/HSI/LAP/ZJU 进行对比，并作为联合模型的临床骨架
尿液代谢组学	约 100+ 尿液代谢物	有机酸、氨基酸、脂肪酸、胆汁酸、糖代谢相关物质、嘌呤/嘧啶代谢物、炎症介质及肠源性代谢物等	用于差异代谢物筛选、代谢通路重编程分析和联合机器学习建模
NHANES 2017-2020	公开临床骨架数据	BMI、腰围、肝功、血脂、血糖、血压及 FLI/HSI 等评分变量	用于临床变量跨人群泛化支持，并与 FLI/HSI/LAP/ZJU 评分对比
GEO 肝转录组	公共肝组织转录组	GSE130970、GSE89632、GSE48452 等 NAFLD 肝组织数据	用于代谢物相关通路的肝组织方向性桥接，支持机制解释
Metabolomics Workbench	公开尿代谢组数据	如 ST000917 等尿代谢组和临床数据集	用于候选尿液代谢物或同类代谢物方向一致性验证和通路层支持
GWAS Catalog	公开遗传关联数据	非酒精性脂肪肝病、代谢综合征、血脂、肝酶及相关代谢表型 GWAS 结果	作为可选探索性遗传支持；若工具变量不足，不作为主线图

注：公共数据库的定位：Metabolomics Workbench 用于尿代谢物方向一致性支持，NHANES 用于临床骨架泛化与传统评分对比，GEO 用于肝组织通路桥接，GWAS/MR 仅作为可选探索性遗传支持。

【研究假设】

非酒精性脂肪肝病高风险表型并非仅由单一临床指标决定，而是由临床代谢异常、尿液代谢重编程和个体表型特征共同反映。临床生化指标能够提供基础风险骨架，尿液代谢组能够捕捉能量代谢、脂质代谢、胆汁酸代谢、氨基酸代谢和氧化应激相关的系统性变化。

在系统化 ML 框架下，临床生化与尿液代谢组联合模型应优于单独临床模型或单独代谢组模型；SHAP 可解释性、公共数据库方向桥接和简化评分工具可增强模型的可信度、可解释性和临床转化潜力。

【分析声明】

本项目的分析方案与预期结果均基于现有数据结构和理想分析条件制定。正式分析前，终点可构造性、尿液代谢物质量、公共代谢组数据匹配度和 GWAS 工具变量强度仍存在不确定性。分析过程中应优先保证嵌套交叉验证和特征选择流程的严谨性，避免 AUC 高估。

【研究路线】

模块（一）：终点设计与高风险表型定义

数据/样本：院内 566 例样本临床生化和代谢指标。

分析工具：严重度分层、代谢高风险复合表型构建。

模块目标：按优先级构建终点：代谢高风险复合表型；若无法构造，才退回普通非酒精性脂肪肝病与健康对照分类。

模块（二）：数据整理与特征工程

数据/样本：临床生化变量、尿液代谢物、证型及四诊信息。

分析工具：Boruta、LASSO、VIF、Wilcoxon FDR、随机森林重要性排序、标准化和变量筛选一致性评估。

模块目标：构建三种特征空间：临床生化 C、尿液代谢物 M、临床生化+尿液代谢组 C+M。临床层面采用 Boruta、LASSO 和 VIF 筛选；代谢层面采用 Wilcoxon FDR、Boruta 和 RF importance 筛选；最终保留两种以上方法共同选中的变量。

模块（三）：嵌套交叉验证与信息泄漏控制

数据/样本：三种特征空间下的训练集与测试折样本。

分析工具：外层 5-fold stratified CV 重复 10 次，内层 5-fold CV 用于超参数调优；每折训练集内完成标准化和特征选择。

模块目标：确保所有特征选择、标准化和模型调参均在交叉验证内部完成，杜绝信息泄漏，获得较可信的模型性能估计。

模块（四）：八算法基准测试

数据/样本：C、M、C+M 三种特征空间及对应终点标签。

分析工具：Logistic、LASSO、ElasticNet、Random Forest、XGBoost、LightGBM、SVM、TabNet；DeLong test、Hosmer-Lemeshow 校准检验。

模块目标：完成三种特征空间×八种算法的全矩阵比较，输出 AUC、Sensitivity、Specificity、PPV、NPV、Brier Score 等指标，形成算法热图、最佳模型 ROC、校准曲线和 DCA 曲线。

模块（五）：SHAP 可解释性分析

数据/样本：最佳模型、核心临床变量及核心尿液代谢物。

分析工具：SHAP summary plot、SHAP dependence plot、SHAP waterfall、SHAP force plot。

模块目标：从全局和单病例两个层面解释模型：识别驱动预测的关键特征，展示关键代谢物风险

曲线，并解释低/中/高风险个体为何被模型判定为相应风险层级。

模块（六）：公共数据库桥接

数据/样本：Metabolomics Workbench 尿代谢组、NHANES 2017-2020、GEO 肝转录组、GWAS Catalog。

分析工具：代谢物方向一致性分析、通路重复出现分析、临床变量泛化、FLI/HSI/LAP/ZJU 评分对比、GEO 通路富集桥接及可选 GWAS/MR 探索。

模块目标：验证院内候选代谢物或同类代谢物方向是否一致，检验脂质代谢、胆汁酸代谢、氨基酸代谢和氧化应激等通路是否重复出现，并用 NHANES 支持临床变量跨人群泛化。

模块（七）：临床部署与转化输出

数据/样本：最终核心变量、最佳模型、简化评分面板及代表性患者案例。

分析工具：简化评分、Nomogram、Shiny 在线计算器雏形、风险分层案例、NRI/IDI 与传统评分对比。

模块目标：输出 ≤ 10 个变量的简化评分工具、在线计算器雏形、低/中/高风险三类患者案例及管理建议，并与 FLI/HSI/LAP/ZJU 等现有评分进行对比，增强实际应用价值。

【研究亮点】

本研究将临床生化、尿液代谢组和证型资料纳入统一的系统化 ML 框架，不再停留于单一算法或单一组学层面的非酒精性脂肪肝病识别，而是面向高风险非酒精性脂肪肝病或进展倾向非酒精性脂肪肝病的无创分层。方法学亮点在于采用嵌套交叉验证避免 AUC 高估，使用八算法基准测试建立稳健比较，结合 SHAP 实现全局和单病例解释，并通过 Metabolomics Workbench、NHANES 和 GEO 进行外部方向性支持。